

Uso de recursos e avaliação de capacidade

Recursos: 07/10/2026 · Contas e estimativas: 08/10/2026

CAPACIDADE PARA CRESCER COM MARGEM OPERACIONAL

O cluster apresenta folga de processamento na carga observada. Os limites mais próximos estão na memória e no crescimento do Supabase Nano, na franquia de tráfego, no orçamento diário do Darcy e na concentração dos serviços em um único nó.

CONTAS CADASTRADAS

3.671

total no Supabase Auth
3.620 perfis na aplicação

DARCY NO USO OBSERVADO

17–32

usuários de IA por dia
7,3 perguntas por pessoa


TRÁFEGO NO USO OBSERVADO

~165

contas ativas por dia
cenário com 20% de reserva

Como interpretar os números

O total cadastrado é uma contagem de contas. Os indicadores diários são projeções de franquia e orçamento, baseadas no perfil observado. A capacidade simultânea permanece a validar por teste de carga; estes números não certificam desempenho ou disponibilidade.



1 Escopo e leitura dos resultados

ANÁLISE EM SOMENTE LEITURA

A inspeção ocorreu em 7 de outubro de 2026, aproximadamente entre 23h31 e 23h41, no horário de Brasília. Abrange os serviços NoFluxo do namespace `non-business-apps`, o cluster K3s compartilhado, o projeto Supabase e os registros de uso do Darcy. Os recursos são uma fotografia daquele momento. Em 8 de outubro, foram acrescentadas consultas agregadas de contas e atividade diária. As novas projeções mantêm os mesmos recursos, franquias e orçamento; suas hipóteses estão explicitadas nas seções de uso diário.

Os endpoints de saúde do frontend, backend e Darcy hospedados no cluster responderam HTTP 200 e informaram o commit abaixo, correspondente ao checkout inspecionado:

Revisão observada

```
c57fb02cc1b2ea3dd920a2566d01b66c6ef7f7a7
```

A Deploy API confirmou o ingresso do frontend em <https://no-fluxo.crianex.com>. O README também divulga `no-fluxo.com`; esse domínio não resolveu na rede usada pela inspeção, de modo que seu caminho público de acesso não foi validado. A leitura dos endpoints de saúde confirma versão e disponibilidade pontual, sem validar jornadas completas de usuários.

Três conceitos distintos

Conceito	O que representa
Uso medido	CPU, memória, conexões, armazenamento e consumo de franquias efetivamente observados.
Reserva e limite	<i>Requests</i> reservam recursos para o agendamento; <i>limits</i> restringem cada contêiner. Reservas não equivalem a uso real.
Capacidade segura	Volume sustentado de usuários e operações que atende critérios de latência, erros, disponibilidade e margem operacional. Exige validação sob carga.

MAU: usuários ativos mensais. p95: percentil 95; em uma amostra, cerca de 95% dos valores ficam abaixo desse patamar. GB/MB usam base decimal; GiB/MiB usam base binária.

Conclusões principais

1. O cluster utilizava cerca de 7,9% da CPU e 29,2% da RAM alocável. A baixa utilização atual não mede o teto de usuários.
2. Todos os serviços NoFluxo estavam no mesmo nó, com uma réplica por serviço e sem escalonador automático horizontal.
3. O Supabase Free/Nano usava cerca de 61–64% da cota do banco e apresentava paginação ativa em memória de troca.
4. A franquia de tráfego permite planejar aproximadamente 1.000 usuários ativos mensais no padrão estimado de uso, mantendo 20% de reserva.
5. O uso observado aponta 60 contas autenticadas/dia, em média. A franquia de tráfego sugere cerca de 165/dia com o mesmo perfil; o Darcy comporta 17–32 usuários de IA/dia com 7,3 perguntas por pessoa e 20% de reserva.

Nenhuma configuração de produção, conteúdo de banco, plano de cobrança ou orçamento foi alterado. Não houve chamada paga a modelo de IA nem execução de teste de carga.

2 Base de usuários e atividade diária

CONTAGEM REAL E REFERÊNCIA PARA AS PROJEÇÕES

A consulta de 8 de outubro de 2026, às 01h55 de Brasília, confirmou **3.671 contas no Supabase Auth** e **3.620 perfis na aplicação**. A diferença é de 51 contas; sua causa não foi investigada. Contas não comprovam pessoas únicas: não houve exclusão de testes nem deduplicação de cadastros.

Indicador	Quantidade	Referência
Total de contas cadastradas	3.671	Auth; reconfirmado em 08/10.
Perfis públicos da aplicação	3.620	Reconfirmado em 08/10.
Último login nos últimos 30 dias	450	Fotografia de 07/10.
Novos cadastros em sete dias	48	Fotografia de 07/10.
MAU faturável do ciclo	352	Painel; ciclo 14/09–14/10.
Contas distintas com atividade em sete dias	263	01–07/10, calendário UTC.

O que foi contado por dia

Contas distintas com evento de login, cadastro ou renovação de token nos registros de autenticação, vinculadas a contas existentes. Uma conta entra uma vez por dia; a mesma conta pode aparecer em dias diferentes. Nenhum identificador pessoal foi retornado. É um **indicador aproximado de atividade autenticada**: renovação automática pode ocorrer sem interação humana, e visitantes sem login ficam fora.

Dia UTC	Contas ativas	Com login	REST	Auth API
01/10	80	29	15.034	807
02/10	74	25	19.689	1.197
03/10	38	11	10.324	445
04/10	21	2	10.381	254
05/10	54	11	11.923	493
06/10	80	25	17.419	917
07/10	73	23	19.284	1.119
Média/dia	60	18	14.865	747

Sete dias UTC completos: de 01/10 às 00h a 08/10 às 00h; em Brasília, de 30/09 às 21h a 07/10 às 21h. O agrupamento parcial de 08/10 foi excluído. “Com login” exclui quem só renovou sessão ou se cadastrou.

Base de cálculo

A soma é de 420 presenças diárias de contas, não 420 pessoas distintas. O máximo foi de 80 contas/dia. Foram 104.054 requisições REST e 5.232 de Auth nos sete dias completos: aproximadamente **248 requisições REST por presença diária de conta**. Esse quociente inclui tráfego de fundo, administração e robôs; não é consumo individual atribuído.

As projeções usam $D_0 = 60$ contas/dia. O tráfego faturado usa cerca de 24 dias; CPU usa histórico de sete dias e a fotografia do banco; IA usa o dia de Brasília. As janelas se sobrepõem, mas não coincidem. A conversão é uma aproximação de planejamento.

3 Cluster e agendamento dos serviços

A chamada `GET /api/k8s/capacity` retornou quatro nós prontos, 14 núcleos de CPU e 54,64 GiB de RAM alocáveis. O uso pontual era de 1,107 núcleo e 15,98 GiB. As reservas de agendamento somavam 7,19 núcleos e 11,66 GiB.

CPU efetivamente utilizada no cluster 7,9%



CPU reservada para agendamento no cluster 51,4%



Memória efetivamente utilizada no cluster 29,2%



Nó	CPU	CPU usada	CPU reservada	RAM usada	RAM reservada
cloud-control-pane	4	5%	6%	21%	1%
non-business-node-1	2	10%	72%	47%	46%
servidor-3	4	11%	75%	41%	30%
servidor-4	4	6%	63%	17%	21%

CPU: núcleos alocáveis. Percentuais por nó arredondados pela Deploy API.

Espaço disponível no sistema de arquivos raiz

Nó	Disponível	Tamanho total
cloud-control-pane	191,87 GB	206,90 GB
non-business-node-1	75,82 GB	100,81 GB
servidor-3	67,05 GB	201,63 GB
servidor-4	170,38 GB	201,63 GB

A API classificou o cluster como `warn` devido à reserva de 75% da CPU em `servidor-3`. O campo `headroomPct` retornou 75, mas a implementação usa esse campo para a maior pressão de reserva: o valor não significa 75% de capacidade livre.

Folga utilizável pelo NoFluxo

Os três serviços estão em `non-business-node-1`. O seletor exige `workload-class=non-business`; apenas esse nó possuía o rótulo. Cada contêiner solicita 100m de CPU e 128 MiB de RAM, com limites de 500m e 512 MiB. Uma unidade de 100m equivale a 0,1 núcleo de CPU. As atualizações permitem um pod adicional temporário e zero pods indisponíveis.

Há 565m de CPU sem reserva nesse nó. Pela aritmética de CPU, caberiam cinco pods adicionais de 100m, restando apenas 65m. Com teto operacional de reserva em 80%, cabe **um** pod adicional. Duplicar os três serviços elevaria a reserva de 71,75% para 86,75%, antes do pod temporário da atualização.

Disponibilidade

Um segundo nó elegível permite distribuir réplicas e enfrentar a perda de um nó. A folga total do cluster não fornece essa proteção automaticamente, pois as regras atuais de agendamento concentram o NoFluxo.


4 Histórico de consumo do NoFluxo

A Deploy API forneceu sete dias de histórico, com 2.017 amostras por aplicação em intervalos de cinco minutos. Os valores abaixo somam os pods de cada aplicação, inclusive sobreposições temporárias de atualização. Picos curtos podem ocorrer entre amostras.

Serviço	CPU média	CPU máxima	RAM média	RAM máxima total
Backend	0,75m	50,77m	65,37 MiB	136,68 MiB
Frontend nginx	0,094m	0,776m	3,38 MiB	3,65 MiB
Darcy FastAPI	5,34m	25,99m	217,51 MiB	229,43 MiB

Máximos amostrados; a coluna de RAM máxima é total por aplicação e não pico isolado de um contêiner. O limite de cada contêiner é 500m de CPU e 512 MiB de RAM.

Memória média comparada ao limite de um contêiner



O pod atual do backend utilizava aproximadamente 61,9 MiB; o Darcy, 220,4 MiB. Os pods atuais registravam zero reinicializações. O relatório histórico também indicou zero incrementos de reinicialização e nenhum motivo de falha. A quantidade de pods históricos distintos inclui substituições de versões e não corresponde a réplicas simultâneas.

Consumo do nó e tráfego de rede

O exportador do nó NoFluxo registrou CPU média de 14,4% e máximo de 58,2%, em médias de cinco minutos. Sua cobertura corresponde a aproximadamente 5,4 dias dos sete solicitados. Esses valores incluem os demais processos e cargas compartilhadas do nó.

A taxa máxima observada de saída pelas interfaces físicas foi de 0,207 MB/s, aproximadamente 1,65 Mbit/s. É tráfego agregado do nó. A velocidade contratada da rede, a franquia mensal de transferência e eventuais restrições do provedor não estavam disponíveis. Por isso, essa taxa não define capacidade de usuários da rede.

Memória reservada e concorrência do Darcy

A reserva de 128 MiB do Darcy é inferior ao conjunto de memória observado, próximo de 220 MiB. Convém revisar essa reserva ao dimensionar o agendamento.

A imagem utiliza dois processos Uvicorn. No endpoint de recomendação sem transmissão contínua, chamadas síncronas aos provedores são executadas dentro de um manipulador assíncrono. O endpoint de transmissão contínua utiliza um gerador síncrono. A concorrência desses caminhos precisa ser testada separadamente; CPU média baixa não comprova que ambos suportam grandes filas de requisições.

Interpretação operacional

Os dados atuais favorecem investimento em disponibilidade, memória do banco e observabilidade antes de expansão geral por CPU. O frontend estático apresenta consumo muito baixo na carga observada; seu teto simultâneo continua dependente de teste e da rede.

5 Supabase e recursos de processamento

A API de gerenciamento confirmou o projeto NoFluxo, região São Paulo, estado `ACTIVE_HEALTHY`. O painel confirmou **plano Free** e instância **Nano t4g.nano**.

Recurso	Observação e interpretação
RAM	443,7 MB reportados pela instância; 182–199 MB disponíveis nas leituras. O orçamento de memória é pequeno.
Memória de troca	631,1 MB ocupados de 1,074 GB. A ocupação pode refletir uso anterior; os contadores também cresceram durante a inspeção.
CPU	5,45% de tempo não ocioso em duas coletas separadas por 349 segundos; 3,05 pontos percentuais correspondem a espera de entrada/saída.
Paginação	75,7 páginas/s lidas da memória de troca e 72,5 páginas/s escritas. Há sensibilidade a memória e entrada/saída.
Conexões PostgreSQL	16 ao banco <code>postgres</code> em uma coleta; 24 no conjunto dos bancos durante a auditoria. Máximo configurado: 60.
Pool do PostgREST	Máximo de 10 conexões; 9 disponíveis e 1 requisição aguardando em uma coleta. Contador de expiração de espera: zero.
Volume de dados	7,72 GB disponíveis de 8,35 GB no sistema de arquivos. Essa folga não amplia a cota de 500 MB do banco no plano Free.

Prioridade antes de um pico de matrícula

Aumentar a capacidade de processamento do Supabase antes de um grande pico. A utilização baixa de CPU não elimina a paginação ativa nem a limitação de memória e entrada/saída. A escolha do tamanho deve acompanhar o teste das operações reais.

Conexões não equivalem a usuários

As conexões PostgreSQL incluem serviços internos e conexões ociosas reutilizadas. As requisições HTTP ao banco compartilham o pool de dez conexões do PostgREST. Uma pessoa pode disparar várias consultas, e uma conexão pode atender várias pessoas ao longo do tempo.

O limite de 60 conexões PostgreSQL não é um limite de 60 usuários. Para acompanhamento operacional, propõe-se manter no máximo sete posições do pool continuamente ocupadas, monitorando fila e tempo de espera. Esse alvo de utilização não fornece, por si só, um teto de usuários simultâneos.

Leituras pontuais e diferenças entre métricas

O gráfico geral do painel mostrou percentuais de CPU e RAM próprios de sua janela. As duas coletas de métricas deste relatório fornecem outro intervalo, de aproximadamente seis minutos. Não se deve tratar diferenças entre janelas como crescimento comprovado de carga.

A documentação oficial do Supabase distingue recursos de CPU, memória, entrada/saída de disco e conexões. O desempenho depende da combinação desses limites e do perfil de consultas. As referências estão reunidas ao final do documento.

6 Banco de dados e crescimento do armazenamento

O banco `postgres` ocupava **302.723.887 bytes**, aproximadamente 303 MB, frente à cota de 500 MB do plano Free. O resumo da organização mostrava 318 MB, enquanto o painel detalhado e a consulta SQL concordavam com 303 MB. Para planejamento conservador, adota-se o maior valor até reconciliar a diferença de contabilização.

Maiores alocações de tabelas

Dados armazenados	Alocação total
Vetores de disciplinas	60,28 MB
Histórico de eventos acadêmicos	46,18 MB
Disciplinas por curso	42,51 MB
Auditoria de autenticação	32,78 MB
Histórico de turmas	23,92 MB
Tokens de renovação de sessão	17,84 MB
Históricos acadêmicos de estudantes	14,17 MB

Históricos de catálogo e de autenticação podem crescer sem novos cadastros. Algumas estimativas de linhas vivas em `pg_stat_user_tables` estavam defasadas; elas não devem ser usadas como contagem exata. Consultas agregadas diretas encontraram 26.145 linhas de vetores e 150.836 relações de disciplinas por curso.

Usuários e carga de consultas observada

Havia 3.671 usuários cadastrados no Auth, 3.620 perfis públicos e 450 usuários com último login nos 30 dias anteriores. A contagem de último login difere de MAU, que também considera renovação de tokens e segue o ciclo de cobrança.

A resposta de sete dias da API inclui agrupamentos UTC de 1 a 8 de outubro, com o último período parcial: 107.103 requisições REST e 5.350 de autenticação. A maior hora recente concentrou 1.563 requisições REST, média de 0,434 requisição/s naquela hora. Essa média não mede o pico por segundo nem uma taxa sustentável máxima.

Cenário de crescimento por conta

As tabelas associadas a usuários alocavam aproximadamente 83,76 MB, ou 22,8 KB por usuário cadastrado, incluindo custos compartilhados de autenticação e histórico. Isso não mede o custo marginal de uma nova conta.

Assumindo **50 KB por conta adicional**, catálogo fixo e teto operacional de 400 MB:

$$N_{\text{adicional}} = \frac{400 \text{ MB} - S_{\text{atual}}}{50 \text{ KB}} \Rightarrow \text{aproximadamente } 1.640\text{--}1.946 \text{ contas.}$$

Histórico, índices, espaço desperdiçado e novo catálogo podem reduzir essa quantidade. Trata-se de cenário de armazenamento, sem garantia de desempenho.

Consultas relevantes para o teste

Estatísticas cumulativas apontam cerca de 563 ms de execução média para uma categoria de busca vetorial e 340 ms para `casar_disciplinas`. Elas misturam cargas e versões passadas: ajudam a selecionar operações para teste, mas não medem o p95 atual da jornada completa nem a capacidade segura de consultas/s.

7 Franquias do Supabase e outros recursos

O ciclo observado é **14 de setembro a 14 de outubro de 2026**. Os medidores podem atrasar; MAU pode levar até 24 horas para atualizar.

Recurso	Uso no ciclo	Franquia	Consumo
Tráfego sem cache	1,16 GB	5 GB	23,2%
Tráfego com cache	0 GB	5 GB	0%
Banco, resumo	318 MB	500 MB	63,6%
Usuários ativos mensais	352	50.000	0,70%
Arquivos no Storage	4,90 MB / 15 objetos	1 GB	0,49%
Pico de conexões Realtime	3	200	1,5%
Mensagens Realtime	80	2.000.000	0,004%
Invocações de Edge Functions	2	500.000	0,0004%
Ingestão de registros	1,167 GB	1 GB	116,7%
Consulta a registros	2,143 GB lidos	100 GB	2,14%

O painel arredonda o Storage para 0,005 GB. A cota do banco é por projeto. Os demais períodos seguem o medidor do ciclo.

Ingestão de registros acima da franquia

O consumo já ultrapassou o limite exibido de 1 GB. Na data observada, o Supabase informa carência até o início de 2027: os avisos são informativos e ainda não aplicam cobrança ou restrições por esse consumo.

Projeção de tráfego e usuários ativos mensais

Com aproximadamente 24 dias transcorridos, o ritmo de tráfego projeta 1,45 GB em um ciclo de 30 dias. Relacionando esse valor aos 352 MAU atuais:

$$\frac{1,16 \text{ GB} \times (30/24)}{352} \simeq 4,12 \text{ MB/MAU/ciclo}, \quad \frac{4 \text{ GB}}{4,12 \text{ MB}} \simeq 970 \text{ MAU}.$$

O envelope de planejamento é **aproximadamente 1.000 MAU**, com teto operacional de 4 GB e 20% de reserva. Inclui tráfego de administração, automações e robôs; pressupõe o mesmo perfil de uso e não constitui atribuição individual ou garantia de desempenho. A franquia de 50.000 MAU do Auth é muito maior que esse envelope de tráfego.

Demais envelopes de franquia

- **Realtime:** 160 conexões simultâneas com 20% de reserva, assumindo uma conexão por cliente. Abrange clientes com assinaturas Realtime, não toda pessoa navegando no site. É o cenário de conexão direta; a alternativa por WebSocket do backend está documentada adiante.
- **Storage:** um teto de 0,8 GB comporta cerca de 159 objetos adicionais de 5 MB, além dos bytes já armazenados. A aplicação pode impor limites menores por upload.
- **Funções:** orçamento de 80% da franquia equivale a 400.000 invocações por ciclo. O número de usuários depende de quantas invocações cada um realiza.

8 Darcy e limites do orçamento de IA

As variáveis inspecionadas não tinham substituições explícitas no manifesto de implantação. A revisão servida coincide com a fonte, cujos valores padrão são:

Proteção	Valor padrão
Limite global do backend por IP	120 requisições/minuto
Limite de IA paga por IP	20 requisições/minuto, além do limite global
Cota individual do Darcy	30 perguntas/dia por usuário
Teto global de custo de IA	R\$15/dia; custo em cache por 60 s

Estudantes no Wi-Fi do campus podem compartilhar o mesmo IP público. Vinte inícios de IA por minuto nesse IP podem atingir o limitador com servidores ociosos. A seis requisições de backend por pessoa por minuto, o limite de 120/min corresponde a 20 pessoas ativas atrás do IP. São cenários de taxa de requisições, não tetos de usuários simultâneos.

Amostra de custos e tempos

Há 80 perguntas vinculadas a registros de uso, das quais 79 tiveram sucesso. O custo médio registrado é **R\$0,04882/pergunta**; o p95 é **R\$0,09270/pergunta**. O p95 da maior duração registrada por pergunta é 15,4 s; ele não representa a latência completa da jornada.

Em 7 de outubro, a tabela de cotas registrou 73 perguntas de dez usuários. O conjunto de chamadas aos modelos registrou custo estimado de R\$3,7294. A diferença de contagem decorre de medidores distintos, e chamadas com falha podem ter sua reserva de cota estornada.

A amostra vinculada é pequena e recente. Os registros antigos incluem 197 chamadas com modelo desconhecido e sem preço, podendo subestimar custos históricos. Não havia saldo atual da Maritaca cadastrado em `ai_saldo_registros`; o painel do provedor exigiu login. Permanecem desconhecidos o saldo efetivo, as cotas da Maritaca de requisições e tokens por minuto e as cotas do projeto Gemini.

Quantos usuários de IA cabem no orçamento

Reservando 20% do teto de R\$15, o orçamento planejado é de R\$12/dia: aproximadamente 245 perguntas no custo médio ou 129 perguntas se cada uma custar o valor de p95.

Perguntas por pessoa/dia	Ao custo médio	Custo p95 por pergunta
5	49 usuários/dia	25 usuários/dia
10	24 usuários/dia	12 usuários/dia
30	8 usuários/dia	4 usuários/dia

O cenário p95 é conservador: esse custo não é o valor esperado de toda pergunta. Os números são estimativas locais de orçamento, sujeitas aos créditos e limites do provedor.

O teto com cache pode ser ultrapassado por requisições já em andamento; ele não equivale a uma trava de gasto aplicada pelo provedor. Para 100 usuários de IA com cinco perguntas cada, os dois cenários exigem cerca de **R\$31–58/dia**, incluindo 20% de reserva, além de créditos e cotas suficientes.

9 Estimativas diárias de processamento

MESMOS RECURSOS E MESMO PERFIL DE USO

Estas projeções respondem ao crescimento de contas ativas *ao longo do dia*. Não indicam pessoas simultâneas nem visitantes totais. Elas isolam CPU e mantêm as réplicas e os limites atuais; memória, rede, filas e disponibilidade podem limitar muito antes.

Modelo condicional para frontend e backend

Parte-se de 60 contas autenticadas/dia e do maior consumo agregado de CPU amostrado em cinco minutos. O alvo é 70% do limite atual de 500m, isto é, 350m por serviço:

$$D_{\text{CPU}} = 60 \times \frac{350 \text{ m}}{\text{CPU}_{\text{máxima observada}}}.$$

Supõe-se crescimento linear e o mesmo padrão de concentração de acessos. Não separamos CPU de inicialização, atualização ou tarefas fixas da CPU causada por pessoas; sobreposição de pods e picos menores que cinco minutos também afetam a estimativa.

Sistema	Pico de CPU	Multiplicador	Projeção apenas de CPU
Frontend nginx	0,776m	451 vezes	~27.000 contas ativas/dia.
Backend Express	50,77m	6,9 vezes	~410 contas ativas/dia.
Supabase Nano	5,45%	12,8 vezes	~770 contas ativas/dia.

Frontend/backend: máximo agregado de sete dias. Supabase: leitura de cerca de seis minutos e alvo de 70% da CPU, não máximo de sete dias. Confiança especialmente baixa na linha do banco. Números arredondados, sem certificação.

Como usar estes números

Os valores representam o que a aritmética de CPU permite *se as hipóteses se mantiverem*. Não adotar 27.000, 410 ou 770 como tetos aprovados do produto. O cenário de tráfego do Supabase é bem menor, e a paginação do Nano já ocorre na carga atual. A visita ao frontend também pode ser anônima e não entrar no indicador de contas autenticadas.

Por que a RAM não foi multiplicada por usuários

Os 3,38 MiB do frontend, 65,37 MiB do backend e 217,51 MiB do Darcy incluem memória fixa dos processos. Não há medida de memória incremental por sessão ou requisição. Multiplicar toda essa RAM pela quantidade de contas produziria uma capacidade artificial. No banco, paginação e entrada/saída podem deteriorar latência mesmo com CPU abaixo do alvo.

Cluster e serviço de IA

A folga total do cluster não entra na fórmula: o NoFluxo só pode agendar no nó elegível atual. Com teto de reserva de 80%, cabe apenas mais um pod de 100m. O pico amostrado do Darcy, 25,99m, tem razão de CPU de 13,5 vezes até 350m; não foi convertido em usuários porque faltou uma série diária comparável de perguntas e concorrência em toda a janela. Seu orçamento, calculado a seguir, oferece um limite diário mais concreto.

10 Estimativas diárias de tráfego, banco e IA

Supabase: cerca de 165 contas ativas por dia

O tráfego sem cache foi de 1,16 GB em aproximadamente 24 dias, equivalente a 48,33 MB/dia. Relacionando esse ritmo às 60 contas/dia da semana recente, obtém-se 0,806 MB por presença diária de conta, incluindo o tráfego não atribuído a usuários.

$$D_{\text{tráfego}} = 60 \times \frac{4 \text{ GB}/30 \text{ dias}}{1,16 \text{ GB}/24 \text{ dias}} \simeq \mathbf{165 \text{ contas/dia.}}$$

É um envelope de franquia de 4 GB por ciclo de 30 dias, com 20% de reserva. Na franquia integral de 5 GB, seriam cerca de 207/dia, sem essa reserva. A projeção assume uso diário distribuído e comportamento constante; não valida o processamento dessas contas no Nano.

Banco: capacidade de cadastros e efeito sobre o uso diário

Com teto de 400 MB, 50 KB por nova conta e catálogo fixo, a base poderia atingir aproximadamente **5.300–5.600 contas cadastradas no total**, incluindo as 3.671 atuais. O cenário original equivale a cerca de 1.640–1.946 contas adicionais.

Hoje, a razão observada é $60/3.671 \simeq 1,63\%$ da base com atividade por dia. Mantendo essa razão durante o crescimento cadastral, o cenário de armazenamento corresponde a **87–92 contas ativas/dia**. Não é um limite de processamento: os atuais 3.671 cadastros podem aumentar sua frequência de uso sem criar contas. Históricos, auditoria, índices e novo catálogo podem consumir a folga antes desse cenário.

Darcy: 17–32 usuários de IA por dia no padrão real

O dia completo de 07/10, em Brasília, foi reconfirmado: 73 perguntas usadas por dez contas, 151 chamadas a modelos e R\$3,7294 estimados. Onze contas aparecem no registro de chamadas; a contagem de dez vem do medidor de cotas positivas. A divisão conservadora inclui todas as chamadas do dia nas dez contas de referência.

$$q = 73/10 = 7,3 \text{ perguntas por conta/dia,} \quad c = 3,7294/10 = \text{R\$0,37294 por conta/dia.}$$

Com R\$12/dia planejados dentro do teto de R\$15, cabem $\lfloor 12/0,37294 \rfloor = 32$ contas/dia no custo observado. Aplicando o custo p95 de R\$0,09270 a cada uma das 7,3 perguntas, o orçamento comporta 17 contas/dia.

Cenários para o conjunto do produto

Mais atividade na base atual: aproximadamente 100–165 contas/dia por franquia e orçamento, se cerca de uma em seis usar IA como na referência de dez usuários de IA para 60 contas/dia. O cenário conservador de IA limita a cerca de 102/dia; o de custo observado permite 192/dia, mas o tráfego limita a 165.

Mais cadastros com frequência constante: o armazenamento sugere 87–92 contas ativas/dia quando a base chegar a 5.300–5.600 contas.

Esses cenários não certificam CPU, memória, latência ou disponibilidade. A fração de usuários de IA compara janelas diferentes e deve ser recalibrada.

11 Demais recursos e resumo das estimativas

Quotas com reserva e conversões condicionais

Sistema	Envelope atual	Conversão para usuários
Supabase Auth	40.000 MAU com reserva de 20%	A razão aproximada 60/352 daria 6.800 contas/dia. É conversão de franquia, sem validar autenticações/s; não é o gargalo atual.
Realtime	160 conexões diretas com reserva	160 contas/dia se conectadas o dia inteiro. Com a ponte no backend, a cota passa a contar conexões dos servidores; capacidade dos clientes exige outro teste.
Storage	0,8 GB; descontar 4,90 MB existentes	159 novos usuários que armazenem um arquivo de 5 MB cada, sem remoção. É capacidade acumulada, não renovada por dia.
Edge Functions	400.000 invocações/ciclo	13.333 usuários/dia com uma invocação por dia. Pode-se mover a execução ao backend; as funções migradas deixam de consumir essa cota, acrescentando carga ao servidor.
Registros de log	1,167 GB já usados em cota de 1 GB	Acima da franquia exibida; carência informativa até início de 2027. Sem separação entre logs de fundo e de usuários, não há teto diário confiável.
Rede, DNS, TLS e registry	Tráfego de saída do nó: pico 1,65 Mbit/s	Faltam capacidade contratada, transferência e demanda individual. Não há base para converter em usuários/dia.

O que cada número permite decidir hoje


- **Frontend:** a projeção de 27 mil/dia é apenas de CPU; capacidade comercial ou pico de visitantes não foi medido.
- **Backend:** cerca de 410/dia pela CPU observada; banco, operações caras e IP compartilhado podem limitar antes.
- **Banco:** cerca de 770/dia pela fotografia de CPU, com baixa confiança; paginação ativa impede tratar esse número como liberação de carga.
- **Tráfego Supabase:** cerca de 165 contas/dia no perfil atual é o envelope quantitativo de franquia para a base existente.
- **IA:** 17–32 usuários/dia no uso observado é o envelope de orçamento, sujeito a créditos e limites dos provedores.

Não foi adotado um único “número seguro” para todo o sistema: cadastro acumulado, atividade diária, usuários de IA, sessões simultâneas e visitantes anônimos medem cargas diferentes. Os cenários diários mantêm a configuração atual; a certificação depende do plano de teste.

12 Alternativa: Realtime centralizado no backend

OPÇÃO INDICADA PELO MANTENEDOR · IMPLEMENTAÇÃO FUTURA

Pode-se substituir as assinaturas Realtime dos navegadores por **WebSockets próprios no backend**. O servidor mantém uma conexão compartilhada com o Supabase Realtime, recebe os eventos e os distribui apenas aos clientes autorizados. O fluxo atual de tickets assina inserções em `ticket_messages` diretamente no navegador, pelo método `subscribeToMessages` do serviço de tickets.



Como muda a capacidade

Na conexão direta, cada WebSocket do navegador ocupa uma conexão do Supabase. Na ponte, N conexões de clientes podem compartilhar uma conexão de origem. O envelope de 160 conexões com reserva deixa de ser um teto de clientes finais desse caminho; continuam existindo limites de conexões, canais, mensagens e tráfego entre Supabase e servidores.

Uma instância com um processo consumidor pode usar uma conexão de origem. Com vários processos, réplicas ou sobreposição de atualização, contar uma por consumidor; para manter um consumidor central, será necessária distribuição interna entre réplicas. Outros clientes ainda conectados diretamente continuam consumindo a cota.

A carga passa para o servidor

A distribuição de um evento para N clientes ocorre no backend. Seu consumo depende de WebSockets abertos, bytes por evento, destinatários, memória das filas e reconexões. As cotas do Supabase não representam capacidade ilimitada do backend. As projeções atuais de CPU foram feitas antes desta mudança e precisam ser recalibradas.

Condições de implementação

- Validar identidade na conexão e permissão em cada assinatura; preservar acesso ao ticket e escopos administrativos. Um consumidor privilegiado não deve repassar todos os eventos a todos os clientes.
- Usar assinaturas compartilhadas por fluxo/tabela e roteamento no servidor, evitando recriar um canal Supabase por cliente. Dimensionar canais e taxa de eventos.
- Implementar WSS no ingresso, expiração de sessão, reconexão, controle de fila para clientes lentos e recuperação por consulta após uma interrupção; não presumir entrega sem perdas ou duplicatas.

Fonte atual: `frontend/src/lib/services/ticket.service.ts`. Referências oficiais: [configurações Realtime](#), [limites e autorização](#).

13 Alternativa: mover Edge Functions para o backend

OPÇÃO INDICADA PELO MANTENEDOR · IMPLEMENTAÇÃO FUTURA

Pode-se portar a lógica das Edge Functions para **rotas e serviços do backend Express**. Processamentos prolongados podem usar execução em segundo plano com fila e concorrência delimitada, conforme a necessidade de cada função. O código Deno deve ser adaptado ao runtime Node/TypeScript; mover a lógica não significa copiar o arquivo sem revisar dependências e contratos.

Impacto nas franquias e nos recursos

Quando o chamador passa a executar a rota do backend e a função hospedada deixa de ser invocada, essa operação deixa de consumir a cota de invocações de Edge Functions. Um proxy no backend que continue chamando a Edge Function ainda consome a cota. A execução passa a disputar CPU, RAM, rede e conexões do servidor.

Antes	Depois da migração
Função hospedada	Chamada ao serviço/rota do backend e execução local.
Franquia de invocações	Deixa de limitar as funções efetivamente portadas; funções remanescentes continuam sujeitas à franquia.
Recursos de execução	Passam ao backend, hoje com limite de 500m de CPU e 512 MiB por contêiner.
Banco e provedores	Consultas, armazenamento, tráfego Supabase e chamadas pagas continuam consumindo seus respectivos recursos.
Disponibilidade	Depende do backend e de seu posicionamento; hoje há uma réplica no único nó elegível.

O que preservar na mudança

Inventariar funções publicadas, chamadores, gatilhos, horários de execução, variáveis de ambiente e dependências. O checkout inspecionado não contém uma pasta `supabase/functions`; as duas invocações registradas no ciclo não identificam por si só quais funções estão publicadas.

Preservar contratos HTTP, validação de JWT, autorização por usuário, permissões administrativas e política de acesso aos dados. O cliente privilegiado de `backend/src/supabase_wrapper.ts` não substitui autorização da rota. Conforme o contrato existente, preservar também assinaturas de webhooks, idempotência, limites de entrada, tempos máximos, retentativas e registros de execução.

Capacidade após consolidar os serviços

A estimativa atual de cerca de 410 contas/dia pela CPU do backend não inclui WebSockets próprios nem funções portadas. Refazer a medição com navegação, IA, distribuição de eventos e funções em conjunto. Operações pesadas precisam de fila ou isolamento para não bloquear a API. A migração amplia as opções de arquitetura, sem ampliar automaticamente a capacidade já medida.

Diretriz documental DEC-CAP-001: registrar estas alternativas, conforme pedido de 08/10/2026. Estado: opções propostas; implementação não iniciada. Referência: [Supabase Edge Functions](#). Nenhuma rota, função hospedada, assinatura ou configuração de produção foi alterada neste trabalho.

14 Limites operacionais e prioridades

O uso medido está abaixo da capacidade de CPU e disco do cluster. A compra de capacidade compartilhada adicional não se justifica apenas por essa utilização. As prioridades são redundância de agendamento, memória reservada do Darcy, recursos do Supabase e orçamento de IA adequado ao público pretendido.

Recurso	Limite proposto	Interpretação
Agendamento	80% da CPU reservada por nó elegível	No nó atual, permite um pod adicional de 100m com essa margem.
Armazenamento do banco	400 MB	20% abaixo da cota Free; cresce também sem novos usuários.
Pool de consultas	Até sete posições continuamente ocupadas em dez	Alvo de acompanhamento, sem conversão direta em pessoas.
Tráfego Supabase	4 GB/ciclo	Cerca de 1.000 MAU no perfil estimado atual.
Realtime direto	160 conexões simultâneas	Uma conexão por cliente; 20% de reserva. A alternativa no backend muda esta relação.
Orçamento de IA	R\$12 de uso planejado em R\$15/dia	17–32 usuários/dia no padrão observado de 7,3 perguntas por pessoa.
Usuários simultâneos	Ainda não validado	Falta curva de demanda e recursos com critérios de aceitação.

Sequência de melhorias

1. **Supabase:** aumentar recursos de processamento antes de um evento de tráfego elevado e acompanhar crescimento do banco rumo a 400 MB.
2. **Disponibilidade:** disponibilizar um segundo nó elegível ao NoFluxo e distribuir réplicas entre nós. Revisar a reserva de memória do Darcy.
3. **IA:** adequar o orçamento ao público diário, confirmar créditos e cotas dos provedores e testar o efeito do IP compartilhado do campus.
4. **Consolidação no backend:** considerar a ponte Realtime com WebSockets próprios e portar Edge Functions para serviços do backend, recalibrando recursos e autorização.
5. **Observabilidade e teste:** medir requisições, erros e latência por jornada e executar validação progressiva com contas sintéticas.

O que impede certificar usuários simultâneos

A análise Umami exposta pela Deploy API retornou zero visitantes e visualizações, enquanto o Supabase mostrou tráfego real. Esses zeros não permitem calibrar usuários. As consultas Prometheus de taxa de requisições, p95 de latência e erros de servidor no ingresso NoFluxo não retornaram séries.

É necessário medir operações por usuário por minuto e associá-las a recursos, filas e latência. Multiplicar a CPU ociosa por um número arbitrário de pessoas produziria um teto sem validação. As estimativas de franquia e orçamento continuam úteis para planejamento, mas respondem a outra dimensão de capacidade.

15 Plano de validação da capacidade segura

Validar em ambiente isolado, com contas sintéticas e perfil de uso representativo. Chamadas a provedores, gravações e injeção de falhas precisam de escopo e orçamento próprios aprovados. Este relatório não executou essas ações.

Progressão da carga

Etapas de usuários simultâneos

25 → 50 → 100 → 200 → 400

Incluir navegação em currículos, importação e correspondência de histórico, planejamento, consultas periódicas de notificações e assinaturas de suporte. Executar perfis separados para início de perguntas de IA e respostas em transmissão contínua, incluindo o cenário de um mesmo IP do campus.

Medir requisições por pessoa por minuto, a taxa efetiva por serviço, os tempos das jornadas e a ocupação de conexões. Após eventual migração, incluir WebSockets abertos, distribuição de eventos, re-conexão, cliente lento e carga das funções portadas. Repetir o maior patamar aprovado em ensaio prolongado. Após implementar redundância de posicionamento, validar também perda de um nó.

Critérios de aceitação propostos

Indicador	Critério para a etapa
Leituras comuns	p95 inferior a dois segundos.
Erros nas operações	Menos de 1%, com classificação de origem e status.
CPU e memória	CPU abaixo de 70% e RAM abaixo de 80%, com janela definida.
Fila e conexões	Sem crescimento contínuo da fila do pool ou aumento de expirações de espera.
Saúde dos contêineres	Sem encerramentos por falta de memória e sem deterioração de disponibilidade.
Franquias	Sem atingir cotas de serviço durante o ensaio.
Experiência de IA	Definir separadamente limites para primeiro trecho recebido e resposta completa.

Interromper o aumento de carga quando um critério falhar. Estabelecer o teto de operação abaixo do maior volume sustentado aprovado, com 20% de reserva. O maior patamar atingido por alguns segundos não substitui aprovação no ensaio prolongado.

Indicadores que precisam ser conectados

- Requisições por serviço, rota, status e período; latência das jornadas.
- CPU real, períodos de limitação de CPU, memória e reinicializações por serviço.
- CPU, memória, paginação, conexões e fila de consultas do Supabase.
- Consumo de tráfego, crescimento diário do banco e cotas Realtime; após migração, conexões WebSocket, atraso dos eventos e filas do backend.
- Custo por pergunta, falhas, créditos e requisições/tokens por minuto nos provedores.

Esses critérios são propostas de aceitação. A aprovação da capacidade simultânea continua pendente da execução e dos resultados.

16 Fontes e rastreabilidade

Medições e artefatos

As fotografias de estado do cluster e o histórico de aplicações vieram da Deploy API. Consultas em somente leitura ao cluster confirmaram recursos, réplicas, posicionamento, ausência de HPA e métricas existentes do Prometheus. O Supabase foi consultado com o token autorizado do ambiente local e o endpoint dedicado a SQL em somente leitura; as franquias vieram do painel autenticado.

- GET /api/k8s/capacity: CPU, RAM e pressão de reservas por nó.
- GET /status/non-business-apps/:app: saúde e réplicas dos três serviços.
- Histórico da Deploy API em /api/k8s/apps/.../metrics: sete dias, passo de cinco minutos.
- API Supabase: projeto, métricas de recursos, contagem de requisições e consultas SQL agregadas.
- Painel de uso: ciclo de 14/09/2026 a 14/10/2026 e franquias observadas.

Os dados agregados são preservados no arquivo de evidências, junto deste documento:

Pacote de referência

[nofluxo-capacity-2026-10-07.evidence.json](#)

[nofluxo-capacity-2026-10-07.md](#)

[nofluxo-capacity-daily-estimates-2026-10-08.json](#)

As consultas adicionais de 08/10 retornaram apenas contagens: total de contas e perfis, contas distintas por dia em login/cadastro/renovação de sessão e consumo agregado do Darcy em 07/10. O arquivo complementar preserva a definição de atividade, as janelas e as fórmulas. Os medidores originais de recursos não foram substituídos.

Documentação dos provedores

1. Supabase — processamento, disco e conexões:
<https://supabase.com/docs/guides/platform/compute-and-disk>
2. Supabase — tamanho do banco e limite Free:
<https://supabase.com/docs/guides/platform/database-size>
3. Supabase — métricas:
<https://supabase.com/docs/guides/observability/metrics>
4. Supabase — aviso sobre cobrança de registros:
<https://supabase.com/changelog/logs-usage-based-pricing>
5. Maritaca — limites de taxa:
<https://docs.maritaca.ai/pt/rate-limits>

As regras dos provedores correspondem às fontes consultadas na auditoria; podem mudar posteriormente.

Identidade visual e adaptação para A4

A paleta foi extraída dos tokens atuais do tema claro em `frontend/src/app.css`: roxo primário 258 77% 56%, texto 260 24% 10%, superfícies lilás e cores semânticas. As conversões RGB usadas são 6C38E5 para o primário, 171320 para o texto e FCFBFE para o fundo.

A tipografia Inter segue `frontend/tailwind.config.ts`. A marca NOFLX UNB utiliza contornos vetoriais de Permanent Marker, fonte indicada no frontend. Cartões, bordas arredondadas e contraste seguem o vocabulário de `nofluxo-ds.css`; transparências e efeitos de vidro foram adaptados para leitura e impressão. Marca e gráficos estão incorporados ao arquivo LaTeX.

Limites e proteção dos dados

Credenciais, perguntas, registros acadêmicos, contatos e texto bruto de consultas foram excluídos. DNS, certificados e registro de imagens são infraestrutura compartilhada; faltaram contratos de transferência e demanda por usuário para estimar sua capacidade separadamente. Saldo e cotas dos provedores de IA permanecem sem confirmação. O relatório preserva essas lacunas sem convertê-las em garantias.